


様々な分布

- 乱数発生器は通常、一様な整数乱数あるいは実数乱数を生成
- 一様分布以外の分布にしたがう乱数の発生方法の代表例
- 逆関数法
 - ▶ 確率分布関数 $F(x)$ の逆関数 $F^{-1}(y)$ と $(0,1)$ の一様乱数 u から $v = F^{-1}(u)$
 - ▶ 例: 指数分布 $p(x) = \frac{1}{\mu} e^{-x/\mu}$
 $F(x) = 1 - e^{-x/\mu} \quad F^{-1}(y) = -\mu \log(1 - y)$
 - ▶ 一般の確率分布関数について逆関数を求めるのは困難
- 棄却法
 - ▶ 確率密度関数を完全に囲むような箱を用意し、その箱の中で一様乱数を生成
 - ▶ 確率密度関数の下側の点が生成されたら、その x 座標を乱数として採用。上側の点の場合には再度生成
 - ▶ もとの確率密度関数よりも箱が大きくなりすぎると非効率

ヒストグラムの作り方

- 連続変数 (実数) のデータの場合 ([] 内はサンプルプログラムでの変数名)
 - ▶ N : サンプル数 [samples]
 - ▶ x_{\min} : データの最小値 (カットオフ) [xmin]
 - ▶ x_{\max} : データの最大値 (カットオフ) [xmax]
 - ▶ n : ビンの个数 [bins]
 - ▶ Δ : ビンの幅 ($\Delta = (x_{\max} - x_{\min})/n$) [dx]
- サイズ n の配列を準備
 - ▶ データ毎にどのビンに入るか計算: $j = (x - x_{\min})/\Delta$
 - ▶ (必要に応じて) $0 \leq j < n$ であることを確認 (範囲外のデータは無視する)
 - ▶ 配列の j 番目の値を 1 増やす
- サンプルプログラム: `histogram.c`
(コンパイルには `mersenne_twister.h` と `cmatrix.h` が必要)



ビンの個数の設定

- 最適の幅というものはない
- 個数を増やすと表現の自由度は増えるが、各ビンのエラーバーが大きくなる
 - ▶ データが統計的に独立である場合、それぞれのビンのカウント数 m はポワソン分布に従う
 - ▶ 統計誤差 $\sim \sqrt{m}$
- いくつかの方法・公式が提案されているが、分布の形によっては不適切な場合も
 - ▶ スタージェスの公式 $n = \log_2 N + 1$
 - ▶ スコットの公式 $\Delta = 3.5\sigma/N^{1/3}$
- 実際には、ビンの個数を何通りか試してみるのが良い
- データを取り直すことが出来ない and/or コストがかかる場合も多いので、生データはいったんファイルに保存しておく