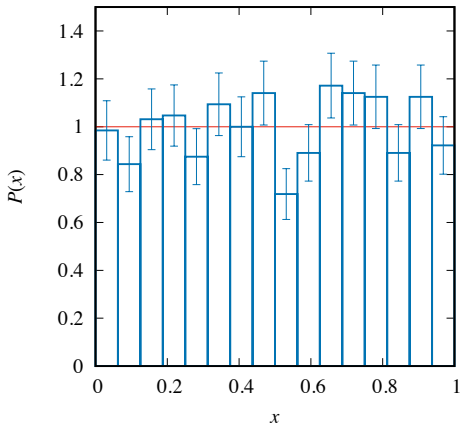
ヒストグラムの作り方

- 連続変数 (実数) のデータの場合 ([] 内はサンプルプログラムでの変数名)
  - N: サンプル数 [samples]
  - $x_{\min}$: データの最小値 (カットオフ) [xmin]
  - $x_{\max}$: データの最大値 (カットオフ) [xmax]
  - n: ビンの個数 [bins]
  - Δ: ビンの幅 ($\Delta = (x_{\max} - x_{\min})/n$) [dx]



- サイズ n の配列を準備
  - データ毎にどのビンに入るか計算: $j = (x - x_{\min})/\Delta$
  - (必要に応じて) $0 \leq j < n$ であることを確認 (範囲外のデータは無視する)
  - 配列の j 番目の値を 1 増やす
- サンプルプログラム: histogram.c
  (コンパイルには mersenne_twister.h と cmatrix.h が必要)

ビンの個数の設定

- 最適の幅というものはない
- 個数を増やすと表現の自由度は増えるが、各ビンのエラーバーが大きくなる
  - データが統計的に独立である場合、それぞれのビンのカウント数 m はポワソン分布に従う
  - 統計誤差 $\sim \sqrt{m}$
- いくつかの方法・公式が提案されているが、分布の形によっては不適切な場合も
  - スタージェスの公式 $n = \log_2 N + 1$
  - スコットの公式 $\Delta = 3.5\sigma/N^{1/3}$
- 実際には、ビンの個数を何通りか試してみるのが良い
- データを取り直すことが出来ない and/or コストがかかる場合も多いので、生データはいったんファイルに保存しておく